

Генерация промоторных последовательностей ДНК


Цель работы

Разработать воспроизводимый генератор бактериальных $\sigma 70$ -промоторов, сохраняющий характерные элементы -35 и -10, но создающий разнообразные последовательности заданной силы. Оценить качество генерации архитектурной метрикой и независимым k-mer-классификатором.

Постановка эксперимента


Использовалось окно длиной 81 нуклеотид (-60...+20 относительно TSS). Консенсусные мотивы: TTGACA для элемента -35 и TATAAT для элемента -10. Спейсер варьировался от 15 до 19 нт. Вероятность мутации мотивов определялась классом силы промотора. Контрольный класс состоял из фоновых последовательностей, не содержащих полной пары близких к консенсусу мотивов.

01_nucleotide_profile



Позиционный профиль позволяет проверить локализацию консенсусных элементов. Для фона частоты нуклеотидов должны быть близки к исходному распределению, а для промоторов — иметь выраженные пики в областях -35 и -10.

02_promoter_heatmap




Тепловая карта показывает частоту каждого нуклеотида по координатам и непосредственно визуализирует сохранность мотивов.


Состав выборки

Положительные примеры равномерно распределялись между сильными, средними и слабыми промоторами. Для контроля использовалось равное число фоновых последовательностей. Все выборки и разбиения воспроизводимы по seed=42.

03_gc_distribution



04_architecture_score




Архитектурный score объединяет сходство обоих мотивов с консенсусом и штраф за отклонение длины спейсера от 17 нт. Ожидается монотонный порядок strong > medium > weak > background.


Оценка классификатором

Для независимой автоматической оценки использована TF-IDF-векторизация символьных k-mer длиной 3–6 и логистическая регрессия. Выделялось 20% стратифицированной hold-out выборки. Устойчивость результата проверялась 5-fold cross-validation.

05_roc_curve



06_confusion_matrix




07_cross_validation




Качество новых кандидатов

После обучения отдельным генератором с независимым seed создавались новые кандидаты трёх уровней силы. Для них вычислялась вероятность класса promoter, доля уникальных последовательностей и среднее попарное различие.

08_generated_quality



09_generated_diversity



Вывод

Разработанный метод генерирует уникальные последовательности, сохраняет основные признаки $\sigma 70$ -промоторов и позволяет управлять степенью отклонения от консенсуса. Архитектурная метрика и k-мер-классификатор дают согласованную оценку силы кандидатов.